Predicting Local LLM Inference Speed from Apple Silicon and LLM Characteristics

Chip Chip 'n' Dale: Вознюк Віра && Карпенко Вікторія

Мета:

Перевірити, чи можна передбачити швидкість генерації локальної LLM на Mac з Apple Silicon ще до запуску моделі, лише з характеристик чіпа та моделі. З'ясувати наскільки машинне навчання покращує просте фізичне правило (швидкість = пропускна здатність пам'яті / розмір активних ваг моделі) і в яких випадках цього правила вже достатньо.

Дані:

Датасет: LLMCheck (https://llmcheck.net/data/benchmarks.csv), завантажено 2026-11-02. Кожен рядок - один результат: модель, квантизація, чип, рушій інференсу і швидкість генерації.

Із 480 рядків лише 193 реально виміряні, решта розраховані сайтом за формулою. Навчаємо і тестуємо тільки на виміряних. Після очистки лишилося 179 рядків: 13 чипів і 47 моделей.

Також ми створили дві допоміжні таблиці: характеристики чипів (пропускна здатність пам'яті, GPU-ядра) і кількість біт на вагу для кожного формату квантизації. (Датасети створені за допомогою AI, на основі офіційної документації Apple)

Методи:

Обробка даних

1. Числа в даних дуже різні, тому розміри, пропускну здатність і саму швидкість ми беремо в логарифмі. Де не вказано RAM, ставимо медіану.
2. Усе це робиться всередині пайплайна, тому під час кросвалідації обробка "вчиться" тільки на тренувальних даних і нічого не підглядає в тестових.

Baseline

1. **Медіана:** завжди передбачає медіанну швидкість
2. **Фізичне правило:** швидкість = a * (пропускна здатність / розмір активних ваг)^b.

Моделі

1. **Ridge:** Дозволяє перевірити наскільки залежність швидкості від характеристик можна описати лінійно.
2. **RandomForest:** встановлює складніші залежності, але не може передбачити швидкість більшу за ту, що бачив у навчанні, тому погано працює на нових, швидших чіпах
3. **Hybrid:** бере фізичне правило за основу, а RandomForest вчить лише поправку.

Перевіряє чи складні моделі кращі за фізичне правило.

Складні моделі не використовували, через маленький датасет(179 рядків). Моделі б швидко перенавчались

Валідація

Спочатку ми відклали тестовий набір: усі рядки двох найновіших чипів, M5 Ultra і M6 (31 рядок). Їх використали лише один раз, у самому кінці. На решті даних (148 рядків, 11 чипів) робили кросвалідацію.

1. **GroupKFold (по чіпах і по моделях):** усі рядки одного чіпа (або однієї моделі) потрапляють в один фолд. Перевіряємо прогноз для чіпа чи моделі, яких модель ще не бачила
2. **KFold:** рядки діляться випадково, тому той самий чіп часто є в навчанні і в тест. Помилка виходить заниженою

Метрики

1. **MAE:** Показує середню абсолютну різницю між реальною та прогнозованою швидкістю.
2. **MAPE:** Дозволяє порівнювати помилки для повільних і швидких моделей.
3. **RMSE:** Допомагає виявити моделі, які іноді роблять особливо великі помилки.
4. **R2:** Показує, наскільки добре модель пояснює варіацію швидкості порівняно з прогнозуванням середнього значення.
5. **Частка в межах +- 20%:** Показує, для якої частини прогнозів відносна помилка не перевищує 20%.

Результати:

Помилка на нових чипах у кросвалідації (GroupKFold по чипах), MAE в токенах/с:

- медіана: 31.2
- фізичне правило: 17.4
- Ridge: 14.4
- Random Forest: 22.5
- Hybrid (правило + Random Forest): 16.9

Помилка на тестових чипах (M5 Ultra і M6), MAE в токенах/с:

- медіана 33.9
- фізичне правило 13.6
- Ridge 13.6
- Random Forest 22.5
- Hybrid 10.6

Просте правило майже вдвічі краще за медіану (помилка менша на 44%). У кросвалідації найкраща Ridge: вона краща за правило в 4 з 5 фолдів, у середньому на 3 токени/с. Hybrid у кросвалідації майже не кращий за правило. На тестових чипах

найкращий Hybrid: MAE 10.6 проти 13.6 у правила, і 61% прогнозів мають помилку до 20% (у правила 52%). Ridge на тесті має таку саму MAE, як правило, але за MAPE гірша. Random Forest сам по собі гірший за правило, бо не вміє передбачати швидкості, більші за ті, що бачив.

Обмеження:

1. мало даних (179 рядків, 13 чіпів)
2. estimated-рядки похідні від виміряних (можливий витік)
3. правило не враховує довжину контексту (KV cache)
4. тестовий набір малий (31 рядок)
5. дані не збалансовані(більшість рядків використовують MLX, а ds4 і rec мають лише один рядок)

Висновки:

Фізичне правило – гарна перша оцінка швидкості. Машинне навчання може його покращити, але виграш невеликий і нестабільний: у кросвалідації краща Ridge, на тестових чипах краща Hybrid, тому назвати одну найкращу модель ми не можемо. Для нових моделей покращення мале. Random Forest сам по собі гірший за правило, тож ML краще використовувати як поправку до фізики, а не замість неї. Частина помилки це шум у самих даних.

